Sandrine Hardy

Concevoir et piloter la gouvernance des données

Projet Spotify

Certification Architecte en Intelligence Artificielle

SPOTIFY
IMPLÉMENTATION

TABLE DES MATIÈRES

1. Organisation, outils et pilote.....3
1.1 Modèle organisationnel : une mise en place en deux temps.....3
1.2 Technologies et outils.....4
1.3 Pilote : données d'engagement utilisateur (Marketing).....4
2. Planning de mise en œuvre.....5
2.1 Feuille de route sur 24 mois.....5
2.2 Conduite du changement et risques.....5

1. ORGANISATION, OUTILS ET PILOTE

1.1 MODÈLE ORGANISATIONNEL : UNE MISE EN PLACE EN DEUX TEMPS

Modèle	Principe	Atouts	Limites pour Spotify
Centralisé	Une équipe unique décide et exécute	Cohérence, contrôle fort	Change brutalement le fonctionnement, éloigné des métiers
Décentralisé	Chaque domaine gouverne ses données	Réactivité, proximité métier, déjà en place	Reproduit les silos si rien n'est structuré
Centre d'Excellence (CoE)	Une équipe centrale fixe les standards ; les domaines les appliquent	Cohérence et proximité métier	Demande un sponsor fort et un changement d'organisation

Recommandation : y aller en deux temps, pour faciliter l'acceptation et réduire la résistance au changement. Spotify fonctionne déjà de façon décentralisée : on part de l'existant, on le structure, puis on rapproche progressivement les équipes dans un Centre d'Excellence.

	Temps 1 : décentralisé structuré (M1 à M12)	Temps 2 : convergence vers le CoE (M13 à M24)
Principe	Pilote dans le département Marketing (M1 à M6), puis, si tout est au vert, déploiement dans tous les départements en gardant le fonctionnement décentralisé : chaque département garde ses équipes et son autonomie, on structure ce qui existe.	Les Data Stewards, Data Engineers et autres profils rejoignent le CoE pour harmoniser les pratiques.
Ce qui change	Un Data Owner et un Data Steward nommés par domaine ; règles minimales communes (la politique) ; une petite équipe de coordination autour du Responsable Data Governance ; comité de gouvernance mensuel.	Standards, catalogue et outils communs gérés par le CoE ; Stewards et Data Engineers rattachés au CoE tout en restant en lien avec leur domaine ; audits communs.
Intérêt	Peu de bouleversement, on s'appuie sur l'existant ; premiers résultats rapides avec le pilote.	Pratiques harmonisées, moins de doublons entre équipes, meilleure intégration des données.
Passage au temps 2	Bilan à M12 : indicateurs atteints et équipes convaincues, puis centralisation.	Le CoE s'étoffe progressivement à partir de M12.

Sigles : CoE (Centre d'Excellence : petite équipe centrale qui définit les standards et appuie les domaines métier) ; Data Owner (responsable des données d'un domaine) ; Data Steward (garant de leur qualité au quotidien) ; Data Engineer (ingénieur qui construit et fait fonctionner le stockage et les flux de données).

1.2 Technologies et outils

Besoin	Ce que l'outil doit permettre	Rôle dans le plan
Catalogue des données	Recenser les jeux de données, leur responsable et leur origine	Source unique de vérité, classification des données
Qualité des données	Repérer les données manquantes, erronées ou en double	Règles de qualité, corrections, tableaux de bord
Conformité et consentement	Tenir le registre des traitements, recueillir et tracer le consentement, gérer les demandes des utilisateurs	Conformité RGPD et lois locales
Sécurité et supervision	Chiffrer les données, surveiller les accès, alerter en cas d'anomalie	Surveillance, alertes, traces pour les audits
Gestion des accès	Donner à chacun l'accès à ce qui est utile à sa mission	Droits selon le rôle et le contexte, revues régulières

Le choix des outils se fera après comparaison de plusieurs solutions et test sur le pilote : compatibilité avec le cloud existant, facilité d'usage, coût sur 3 ans, dépendance à l'éditeur. On privilégie d'abord les outils déjà en place chez Spotify.

1.3 Pilote : données d'engagement utilisateur (Marketing)

Pourquoi ce périmètre. Les données d'engagement (écoutes, interactions, conversions, consentements) concentrent les risques prioritaires : données personnelles, silo entre marketing et produit, qualité qui conditionne les recommandations. Le périmètre est assez limité (un département, trois jeux de données : journaux d'interactions, fichier clients et consentements, événements de conversion) pour réussir en 6 mois, et assez représentatif pour être reproduit. Le pilote a lieu dans le temps 1 : l'équipe Marketing garde son fonctionnement, on lui ajoute un responsable et un référent de la qualité des données. Équipe : sponsor Directeur Marketing, chef de projet Responsable Data Governance, Data Owner et Data Steward Marketing, DPO (délégué à la protection des données), Data Engineer.

Mois	Jalon	Livrable
M1	Cadrage et mesures de départ	Périmètre validé, flux cartographiés, mesures de départ des indicateurs
M2	Audit initial	Rapports qualité et conformité (RGPD, lois locales), statuts confirmés
M3 – M4	Mise en œuvre	Catalogue alimenté, règles qualité, consentement centralisé, accès par rôle et finalité, 1er accord écrit Marketing → Produit
M5	Tests et formation	Retours utilisateurs, formation accessible, audit d'accès
M6	Bilan et go / no-go	Indicateurs finaux, leçons apprises, plan de déploiement dans tous les départements

Indicateur du pilote (départ mesuré en M1)	Cible à M6
Données manquantes sur les champs critiques	− 10 %
Doublons sur la clé utilisateur	− 20 %
Jeux de données du périmètre catalogués (responsable + référent qualité)	100 %
Demandes de droits traitées dans le délai cible	≥ 95 %
Délai d'accès à une donnée autorisée	− 20 %

Go / no-go à M6 : au moins 80 % des cibles atteintes, aucun écart de conformité majeur ouvert, 80 % des analystes du périmètre utilisent le catalogue, budget tenu.

2. PLANNING DE MISE EN ŒUVRE

2.1 FEUILLE DE ROUTE SUR 24 MOIS

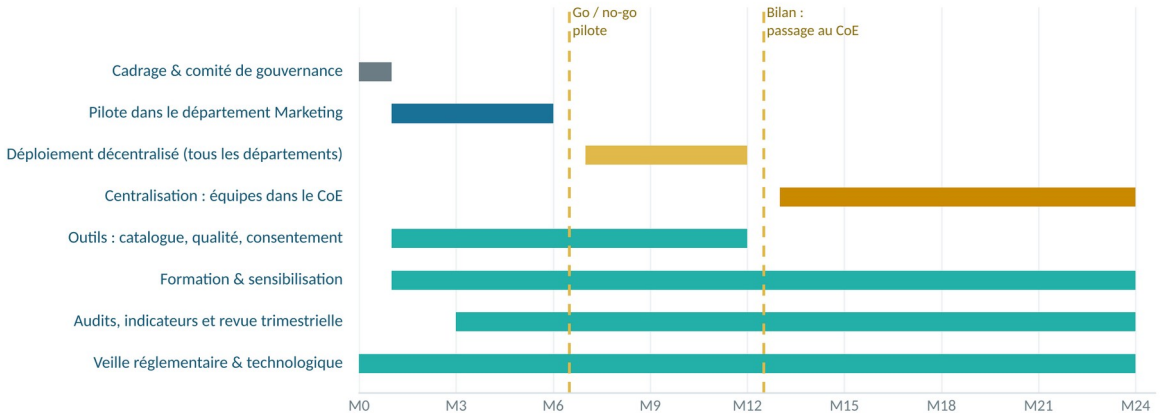


Figure 1 – Feuille de route sur 24 mois (M = mois)

Étape	Périmètre	Points d'attention	Période
Pilote	Département Marketing (données d'engagement)	Valider le modèle, les outils et les indicateurs ; go / no-go à M6	M1 – M6
Déploiement décentralisé (si le pilote est au vert)	Tous les départements, chacun avec son Data Owner et son Data Steward	Ordre selon les risques : paiement (PCI-DSS) et consentement d'abord, puis contenu, produit et IA (inventaire, AI Act, tests de biais)	M7 – M12
Centralisation	Stewards, Data Engineers et autres profils rejoignent le CoE	Pratiques, outils et audits communs ; référentiel unique des données de contenu	M13 – M24

Sigles : PCI-DSS (norme de sécurité des cartes de paiement) ; AI Act (règlement européen sur l'intelligence artificielle).

2.2 CONDUITE DU CHANGEMENT ET RISQUES

Risque	Parade
Résistance au changement, rôles flous	Mise en place en deux temps qui s'appuie sur l'existant ; sponsor visible (CDO, directeur des données) ; ambassadeurs parmi les Stewards ; premiers résultats rapides ; formation par rôle
Qualité plus dégradée que prévu, intégration instable	Audit en M2, priorité aux champs critiques, ingénieurs impliqués dès M1
Dérive du périmètre, retards, budget	Périmètre figé pour chaque étape, revue à chaque jalon, comparaison des outils avant achat
Non-conformité détectée tardivement	Audit du DPO en M2 et M5, veille trimestrielle, politique révisée à chaque évolution
Le temps 2 n'est pas accepté	Bilan à M12 partagé avec les équipes ; les domaines gardent un lien fort avec leurs Stewards et Data Engineers

Coûts (outils, équipe du CoE, formation, audits externes) et bénéfices (moindre exposition aux sanctions, données plus fiables, accès plus rapide) seront chiffrés après la comparaison des outils et le pilote : le business case ne donne pas de données pour le faire ici.