Projet Stripe

From SQL to NoSQL : une architecture de données pour les paiements



Certification Jedha - AIA - Bloc 2 - S. Hardy

Stripe a besoin de trois types de bases

OLTP

Enregistrer les paiements

Des millions de transactions par jour, rapides et fiables (propriétés ACID)

OLAP

Analyser l'activité

Chiffre d'affaires, segmentation des clients, suivi de la fraude

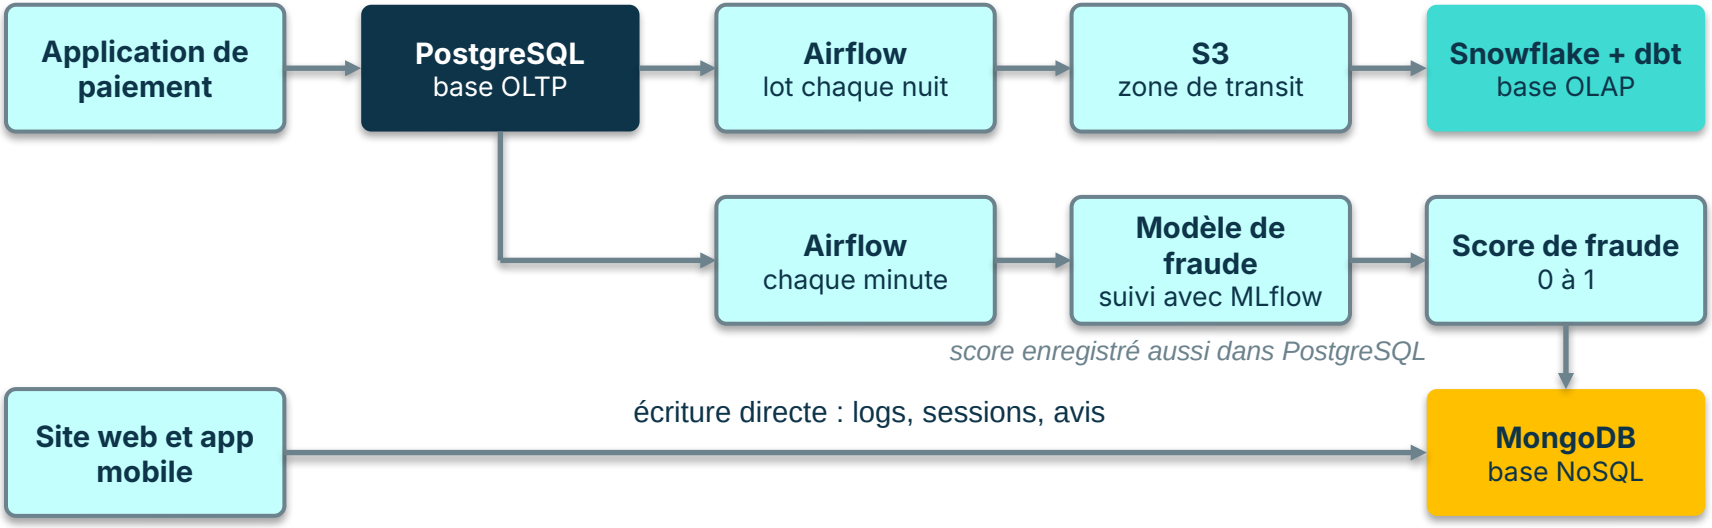
NoSQL

Stocker le non structuré

Logs, clics, avis clients, données d'entrée du modèle de fraude

Contraintes : sécurité, RGPD et PCI-DSS · données cohérentes entre les 3 bases · fraude détectée rapidement

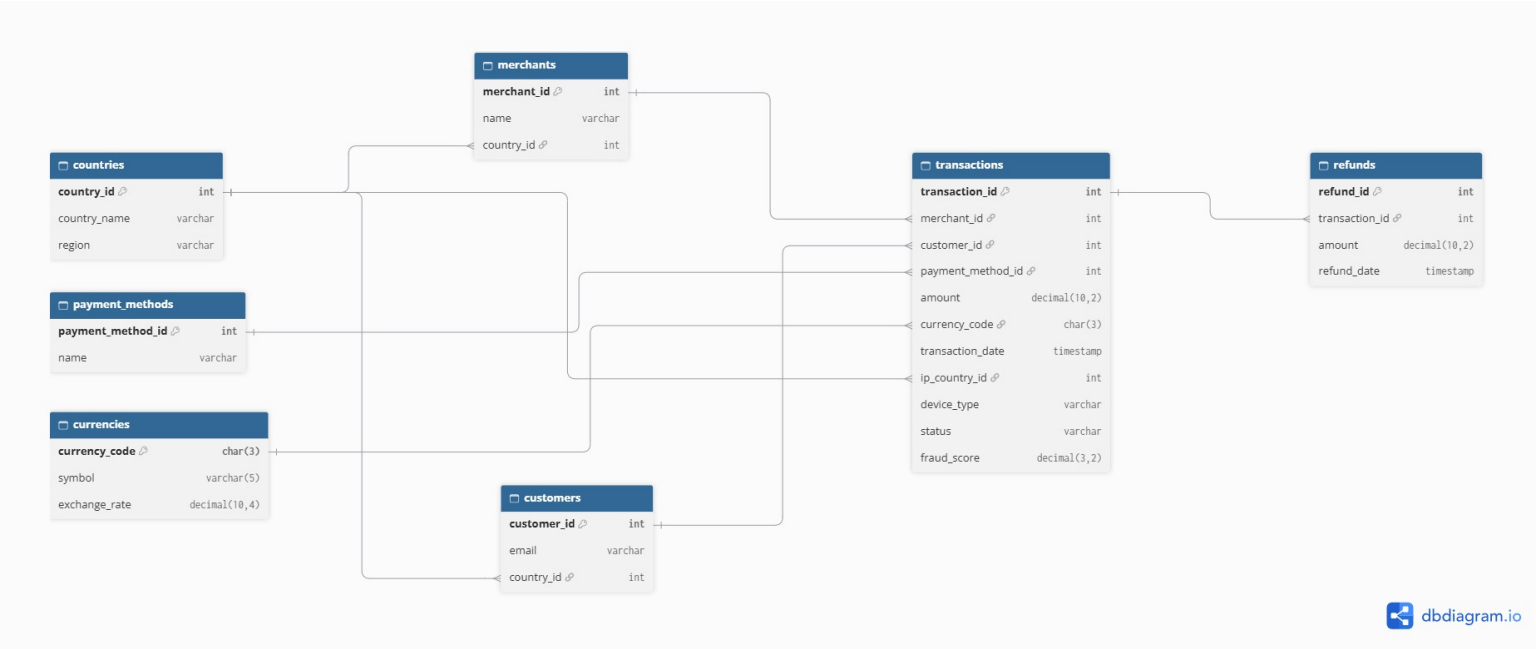
Architecture : trois bases reliées par Airflow



Évolution possible à très grande échelle : remplacer les lots par du streaming (Kafka).

Sécurité sur tout le circuit : chiffrement · accès par rôles · journaux d'audit · RGPD / PCI-DSS

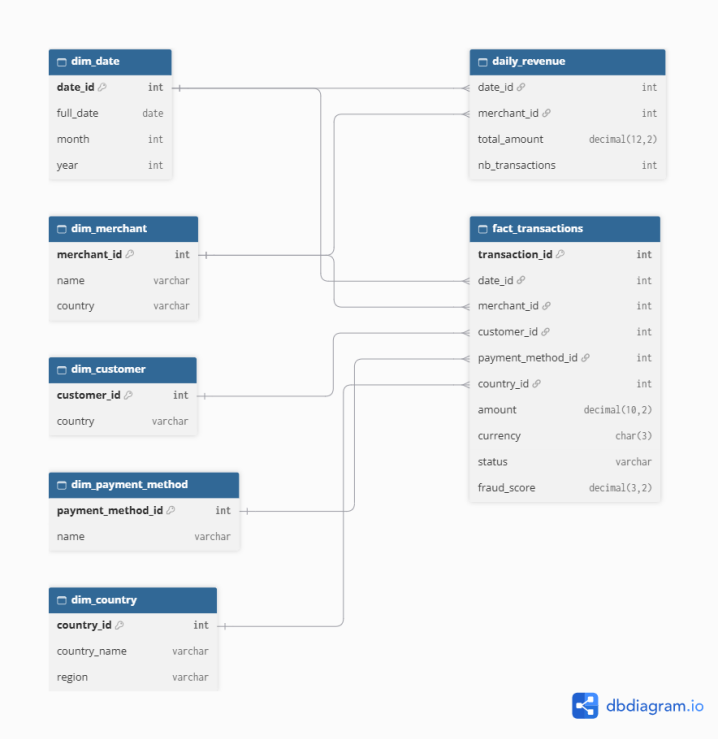
OLTP : enregistrer chaque paiement sans erreur



Normalisé : chaque information une seule fois · ACID : tout ou rien · PostgreSQL (déjà utilisé au bloc 3)

OLAP : analyser vite avec un schéma en étoile

- Table de faits au centre : une ligne = une transaction
- Dimensions autour : date, marchand, client, moyen de paiement, pays (les axes d'analyse)
- daily_revenue : totaux par jour et par marchand, déjà calculés par dbt chaque nuit
- Snowflake : jointures et agrégations rapides sur de gros volumes



NoSQL : des documents pour les données libres

`logs`
Erreurs et accès des services
Référencé : transaction_id

`user_sessions`
Clics et navigation des clients
Imbriqué : events Référencé : customer_id

`ml_features`
Données d'entrée du modèle de fraude et score
Imbriqué : features Référencé : transaction_id

`customer_feedback`
Avis et sondages des clients
Référencé : customer_id, merchant_id

Pipeline : quatre flux, un seul orchestrateur

Source	Format	Fréquence	Cible	Outil
Paiements (OLTP)	Tables SQL, puis CSV	Chaque nuit	Snowflake (faits, dimensions, daily_revenue)	Airflow + S3 + dbt
Nouveaux paiements	Lignes SQL	Chaque minute	Score dans PostgreSQL et MongoDB	Airflow + modèle MLflow
Logs, sessions, avis	Documents JSON	En continu	MongoDB	Écriture directe
Taux de change	JSON (API)	Chaque jour	Table currencies de PostgreSQL	Airflow

ELT
On charge d'abord dans Snowflake, puis dbt transforme sur place

Cohérence
Mêmes identifiants partout. OLAP à J-1, PostgreSQL fait foi

Limite
« temps réel » à la minute

Sécurité et conformité : RGPD et PCI-DSS

Risque	Mesure de protection	Responsable
Fuite de données	Chiffrement des données stockées et des échanges (TLS)	Administrateur système
Accès non autorisé	Droits par rôle : analyste en lecture seule, data engineer, service ML	Responsable sécurité
Perte de données	Sauvegardes quotidiennes et plan de reprise	Administrateur de bases
Manipulation frauduleuse	Journaux d'audit et alertes automatiques	Data engineer
Données de carte	Numéro de carte jamais stocké (PCI-DSS)	Responsable conformité

RGPD
Droit à l'oubli : suppression ou anonymisation par customer_id dans les 3 bases

Rapports
Un DAG Airflow vérifie les règles et produit un rapport de conformité

Surveillance
Alertes en cas d'accès inhabituel

ML : détecter la fraude en continu



Qualité

Précision et rappel de chaque version, enregistrés dans MLflow.

Dérive

On compare les données récentes à celles de l'entraînement pour voir si elles changent.

Mise à jour

Ré-entraînement planifié par Airflow. La nouvelle version ne passe en production que si elle est meilleure.

Autres usages : segmentation des clients (requête Q4), recommandations (évolution).

Jedha

Des questions ?

S. Hardy

